

TimeSformer

Kiến trúc & Pipeline Phát hiện Lửa/Khói
Sử dụng Divided Space-Time Attention

Fire & Smoke Early Detection System

Triển khai trên Modal Cloud — GPU A10G / H100

Hệ thống gồm 5 module chính:

```
train_spatial.py · evaluate_spatial.py  
train_temporal.py · evaluate_temporal.py  
inference_realtime.py
```

Mục lục

1	Tổng quan Hệ thống	2
1.1	Chiến lược Huấn luyện 2 Giai đoạn	2
2	Kiến trúc Mô hình TimeSformer	2
2.1	Sơ đồ Kiến trúc Tổng thể	2
2.2	Sơ đồ DividedSpaceTimeBlock Chi tiết	4
2.3	Cơ chế Multi-Head Self-Attention	4
3	Hyperparameters	4
3.1	Stochastic Depth (DropPath)	4
4	Transfer Learning: Giai đoạn 1 → Giai đoạn 2	6
4.1	Vấn đề tương thích Weights	6
4.2	Xử lý Time Embedding bằng Interpolation	6
4.3	Tại sao temporal_fc init zeros là quan trọng?	6
5	Chuẩn bị Dữ liệu	6
5.1	Giai đoạn 1 — Ảnh tĩnh (YOLO Format)	7
5.1.1	Chuyển đổi nhãn YOLO → Multi-label	7
5.1.2	Pipeline tiền xử lý (Train)	7
5.2	Giai đoạn 2 — Video Clips	7
5.2.1	Cấu trúc thư mục và nhãn	7
5.2.2	Frame Sampling Strategy	8
6	Quá trình Huấn luyện	8
6.1	Cấu hình so sánh hai giai đoạn	8
6.2	Differential Learning Rate (Giai đoạn 2)	8
6.3	Early Stopping với Best-weight Restore	8
7	Đánh giá Mô hình	8
7.1	Bộ Metrics Toàn diện	8
7.1.1	Nhóm 1: Metrics cơ bản (Threshold = 0.5)	10
7.1.2	Nhóm 2: Metrics chuyên sâu (Threshold-Independent)	10
7.1.3	Nhóm 3: Multilabel Confusion Matrix	10
8	Real-time Inference	10
8.1	Sliding Window Architecture	10
9	Tổng kết So sánh	10

1 Tổng quan Hệ thống

1.1 Chiến lược Huấn luyện 2 Giai đoạn

TimeSformer sở hữu hai loại attention hoàn toàn độc lập trong mỗi block:

Loại Attention	Học gì	Dữ liệu cần
Space Attention	Hình dạng, màu sắc, texture lửa/khói trong 1 frame	Ảnh tĩnh
Time Attention	Biến đổi, chuyển động, lan rộng qua nhiều frame	Video clip

Bảng 1. Hai loại attention trong TimeSformer

Hệ thống được thiết kế thành **2 giai đoạn huấn luyện tuần tự**:

Giai đoạn 1 — Spatial Pre-training

`num_frames = 1` $\Rightarrow$ Time Attention gần như vô nghĩa ($T=1$)

Dữ liệu: Ảnh tĩnh YOLO format (`merged_dataset/`)

Mục tiêu: Học nhận biết hình dạng/texture của lửa & khói

Output: `spatial_fire_smoke_weights_v2.pth`

$\downarrow$ *Transfer Learning (strict=False) + Resize time_embedding $T=1 \rightarrow T=8$*

Giai đoạn 2 — Full Spatio-Temporal Training

`num_frames = 8` $\Rightarrow$ Time Attention được kích hoạt hoàn toàn

Dữ liệu: Video clips theo thư mục `fire/`, `smoke/`, `normal/`

Mục tiêu: Học biến đổi không-thời gian của lửa/khói


Output: `full_fire_smoke_weights_v1.pth`

Lý do 2 giai đoạn hiệu quả hơn train end-to-end:

- Dữ liệu ảnh tĩnh dồi dào $\Rightarrow$ spatial features được học tốt từ đầu
- Fine-tune temporal chỉ cần dataset video nhỏ hơn nhiều
- Tránh gradient vanishing khi train từ đầu với chuỗi frames dài


2 Kiến trúc Mô hình TimeSformer

2.1 Sơ đồ Kiến trúc Tổng thể



Hình 1. Kiến trúc đầy đủ của TimeSformerFull (Giai đoạn 2)

2.2 Sơ đồ DividedSpaceTimeBlock Chi tiết



Hình 2. Chi tiết luồng tính toán bên trong một DividedSpaceTimeBlock


2.3 Cơ chế Multi-Head Self-Attention

3 Hyperparameters

3.1 Stochastic Depth (DropPath)

Tỷ lệ drop tăng tuyến tính theo chiều sâu của mạng, từ 0 đến 0.1:


$$\text{dpr}_i = \frac{i}{L-1} \times r_{\max}, \quad i = 0, 1, \dots, L-1, \quad L = 6, \quad r_{\max} = 0.1$$



Hình 3. Cơ chế Multi-Head Self-Attention với $h = 8$ heads, $d_{\text{head}} = 32$

Hyperparameter	Giai đoạn 1	Giai đoạn 2	Ý nghĩa
image_size	224	224	Kích thước frame
patch_size	16	16	Patch 16×16 pixel
num_frames	1 !	8 ✓	Số frames/clip
num_patches	196	196	$(224/16)^2 = 14 \times 14$
num_classes	2	2	Fire + Smoke
dim	256	256	Embedding dimension
depth	6	6	Số DividedSpaceTimeBlock
heads	8	8	Số attention heads
mlp_dim	512	1024	FFN hidden dimension
dropout	0.1	0.1	Dropout rate
attn_drop	0.0	0.1	Attention dropout
drop_path_rate	—	0.1	Stochastic Depth
qkv_bias	False	True	Bias trong QKV projection
temporal_fc	Không có	Init zeros	Residual gate temporal

Bảng 2. So sánh hyperparameters giữa hai giai đoạn




4 Transfer Learning: Giai đoạn 1 $\rightarrow$ Giai đoạn 2

4.1 Vấn đề tương thích Weights

Layer	Shape GD1	Shape GD2	Xử lý
to_patch_embedding.weight	[256, 768]	[256, 768]	✓ Load trực tiếp
pos_embedding	[1, 1, 197, 256]	[1, 1, 197, 256]	✓ Load trực tiếp
time_embedding	[1, 1, 1, 256]	[1, 8, 1, 256]	! Interpolate
layers.*.attn.*	khớp	khớp	✓ Load trực tiếp
layers.*.temporal_fc.*	Không tồn tại	[256, 256]	Init zeros
mlp_head.*	khớp	khớp	✓ Load trực tiếp

Bảng 3. Tương thích weights khi chuyển từ Giai đoạn 1 sang Giai đoạn 2

4.2 Xử lý Time Embedding bằng Interpolation



Hình 4. Quá trình resize `time_embedding` từ $T = 1$ lên $T = 8$

4.3 Tại sao `temporal_fc` init zeros là quan trọng?

Temporal residual = `temporal_fc(temporal_attn(x))` = $\mathbf{W}_{\text{temp}} \cdot (\dots) + \mathbf{b} = \mathbf{0}$ (vì $\mathbf{W} = 0$, $\mathbf{b} = 0$)

Hệ quả: Ở epoch đầu tiên, temporal contribution = 0 $\Rightarrow$ model hoàn toàn giống Giai đoạn 1 (spatial only) $\Rightarrow$ Không phá vỡ spatial features đã học. Temporal_fc sẽ dần học ra giá trị khác 0 theo gradient descent.

5 Chuẩn bị Dữ liệu


5.1 Giai đoạn 1 — Ảnh tĩnh (YOLO Format)

5.1.1 Chuyển đổi nhãn YOLO $\rightarrow$ Multi-label

Class ID (file .txt)	Nhãn	Vector
0	Lửa (Fire)	[1.0, 0.0]
1	Khói (Smoke)	[0.0, 1.0]
Cả 0 và 1	Fire + Smoke	[1.0, 1.0]
Không có	Normal	[0.0, 0.0]

Bảng 4. Ánh xạ YOLO class ID sang multi-label vector

5.1.2 Pipeline tiền xử lý (Train)



Hình 5. Pipeline tiền xử lý ảnh tĩnh (Giai đoạn 1)


5.2 Giai đoạn 2 — Video Clips

5.2.1 Cấu trúc thư mục và nhãn

Nhãn được suy ra trực tiếp từ tên thư mục cha:

- fire/ $\rightarrow [1.0, 0.0]$
- smoke/ $\rightarrow [0.0, 1.0]$
- normal/ $\rightarrow [0.0, 0.0]$

5.2.2 Frame Sampling Strategy



Hình 6. Chiến lược lấy mẫu frames từ video clip

6 Quá trình Huấn luyện

6.1 Cấu hình so sánh hai giai đoạn

Tham số	Giai đoạn 1	Giai đoạn 2
Script	<code>train_spatial.py</code>	<code>train_temporal.py</code>
GPU	NVIDIA A10G (24GB)	NVIDIA H100 (80GB)
Optimizer	Adam, lr= 10^{-4} đồng nhất	Adam, Differential LR
Loss	BCEWithLogitsLoss	BCEWithLogitsLoss
pos_weight	[1.18, 1.71]	[1.18, 1.71]
Epochs tối đa	100	50
Batch size	64	8
Early Stopping	patience = 5	patience = 7
Output	<code>spatial_weights_v*.pth</code>	<code>full_weights_v*.pth</code>


Bảng 5. So sánh cấu hình training hai giai đoạn

6.2 Differential Learning Rate (Giai đoạn 2)


6.3 Early Stopping với Best-weight Restore

7 Đánh giá Mô hình

7.1 Bộ Metrics Toàn diện



Hình 7. Chiến lược Differential Learning Rate trong Giai đoạn 2



Hình 8. Luồng điều khiển Early Stopping với Best-weight Restore

Metric	Ý nghĩa
Precision	Trong các dự đoán Positive, bao nhiêu % đúng
Recall	Trong các nhãn Positive thực tế, bao nhiêu % tìm được
F1-Score	$\frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$
Exact Match Ratio	% mẫu dự đoán đúng hoàn toàn cả 2 nhãn
Hamming Loss	Tỷ lệ nhãn bị dự đoán sai (càng thấp càng tốt)

7.1.1 Nhóm 1: Metrics cơ bản (Threshold = 0.5)

7.1.2 Nhóm 2: Metrics chuyên sâu (Threshold-Independent)

$$\text{ROC-AUC} = \int_0^1 \text{TPR}(t) d\text{FPR}(t) \quad (1)$$

$$\text{AP} = \sum_k (R_k - R_{k-1}) P_k \quad (2)$$

Cả hai được tính per-class và macro-average cho Fire và Smoke.


7.1.3 Nhóm 3: Multilabel Confusion Matrix

$$\text{Per-class: } \begin{bmatrix} \text{TN} & \text{FP} \\ \text{FN} & \text{TP} \end{bmatrix}_{\text{Fire}} \quad \text{và} \quad \begin{bmatrix} \text{TN} & \text{FP} \\ \text{FN} & \text{TP} \end{bmatrix}_{\text{Smoke}}$$

8 Real-time Inference

8.1 Sliding Window Architecture

9 Tổng kết So sánh



Hình 9. Kiến trúc Sliding Window cho real-time inference

Đặc điểm	Giai đoạn 1	Giai đoạn 2
Kiến trúc	TimeSformer	TimeSformerFull
num_frames	1 (nhân tạo)	8 (thực sự)
Time Attention	Trivial (T=1)	Fully active
DropPath	Không	Có (dpr: $0 \rightarrow 0.1$)
temporal_fc	Không	Có (init zeros)
qkv_bias	False	True
Dữ liệu	Ảnh tĩnh YOLO	Video clip thư mục
Augmentation	Flip + Brightness	+ Random clip start
Batch size	64	8
LR Strategy	Uniform 10^{-4}	Differential $10^{-5}/10^{-4}$
Epochs	100 (patience=5)	50 (patience=7)
GPU	A10G 24GB	H100 80GB
Học được	Texture, hình dạng	+ Biến đổi thời gian

Bảng 6. Bảng so sánh đầy đủ hai giai đoạn huấn luyện